

Doğrusal Olmayan En Küçük Kareler

T.C. Trakya Üniversitesi
Mühendislik Fakültesi
Elektrik - Elektronik Mühendisliği Bölümü
Kontrol Anabilim Dalı

Dr. Öğr. Üyesi Işık İlber Sirmatel
sirmatel.github.io

Kaynak (source)

*Lecture Slides for Introduction to
Applied Linear Algebra: Vectors,
Matrices, and Least Squares.*

Stephen Boyd, Lieven Vandenberghe

Konu listesi

1. Doğrusal olmayan denklemler ve en küçük kareler
2. Levenberg-Marquardt algoritması
3. Doğrusal olmayan model uydurma
4. Doğrusal olmayan en küçük kareler sınıflandırma
5. Kısıtlı doğrusal olmayan en küçük kareler
Problem formülasyonu
Ceza yöntemi
Artırılmış Lagrange fonksiyonu yöntemi
Örnek: Doğrusal olmayan kontrol

Bölüm 1

Doğrusal olmayan denklemler ve en küçük
kareler

Doğrusal olmayan denklemler

- n bilinmeyenli (x_1, \dots, x_n) m denklemlili **doğrusal olmayan** (*nonlinear*) denklem takımı:

$$f_i(x_1, \dots, x_n) = 0, \quad i = 1, \dots, m$$

- $f_i(x) = 0$: i . denklem; $f_i(x)$: i . kalıntı
- $x = \begin{bmatrix} x_1 & \dots & x_n \end{bmatrix}$: bilinmeyenler vektörü ($x \in \mathbb{R}^n$)
- denklem takımını vektör denklemi $f(x) = 0$ olarak yazalım ($f : \mathbb{R}^n \rightarrow \mathbb{R}^m$)

$$f(x) = \begin{bmatrix} f_1(x) \\ \vdots \\ f_m(x) \end{bmatrix}$$

- f bir afin fonksiyon (yani, $f(x) = Ax - b$) ise, vektör denklemi m denklemlili doğrusal denklem takımına (yani, $Ax = b$ 'ye) dönüşür

Doğrusal olmayan denklemler

$f(x) = 0$ denklemine ($f : \mathbb{R}^n \rightarrow \mathbb{R}^m$)

- ▶ $m > n$ ise aşırı belirli
- ▶ $m = n$ ise kare
- ▶ $m < n$ ise eksik belirli

denir

Doğrusal olmayan en küçük kareler

- ▶ doğrusal olmayan en küçük kareler (*nonlinear least squares* (NLS)) problemi:

$$\|f(x)\|^2 = f_1(x)^2 + \cdots + f_m(x)^2$$

ifadesini minimize eden \hat{x} 'i bulmak

- ▶ bu problem,

$$\underset{x}{\text{minimize}} \quad \|f(x)\|^2$$

formunda bir optimizasyon problemidir

- ▶ $f(x) = 0$ denklemini çözme problemi, bu problemin bir özel halidir
- ▶ (doğrusal) en küçük karelere benzer şekilde, çok kullanışlı bir yöntemdir

Optimalite koşulu

- problem:

$$\underset{x}{\text{minimize}} \quad \|f(x)\|^2$$

- optimalite koşulu: $\nabla \|f(\hat{x})\|^2 = 0$
- her optimal nokta bu koşulu sağlar, ancak bu koşulu sağlayan her nokta optimal değildir (koşul, gerek koşuldur, yeter koşul değildir)
- koşul şu şekilde ifade edilebilir: $2Df(\hat{x})^T f(\hat{x}) = 0$
- buradaki $Df(\hat{x})$ 'ye **Jakobi** (*Jacobian*) matrisi denir ($Df(\hat{x}) \in \mathbb{R}^{m \times n}$):

$$Df(\hat{x})_{ij} = \frac{\partial f_i}{\partial x_j}(\hat{x}), \quad i = 1, \dots, m, \quad j = 1, \dots, n$$

Doğrusal olmayan en küçük kareler

doğrusal olmayan en küçük kareler problemini çözmenin zorluğu:

- ▶ doğrusal olmayan denklemleri veya doğrusal olmayan en küçük kareler problemini çözmek (genel olarak) doğrusal denklemleri çözmekten **çok daha zordur**
- ▶ bir çözümün mevcut olup olmadığını tespit etmek bile zordur
- ▶ dolayısıyla bunları çözmek için **buluşsal** (*heuristic*) algoritmalar kullanırız (k -ortalamalarda olduğu gibi):
 - bu tip algoritmaların daima çalışacağının garantisi yoktur
 - ancak pratikte genellikle düzgün çalışırlar

Örnek: Denge noktalarının hesaplanması

denge (*equilibrium*) noktalarının hesaplanması

- ▶ denge fiyatları: $S(p) = D(p)$ 'yi sağlayan fiyat vektörü p 'yi bul ($p \in \mathbb{R}^n$)
 - $S(p)$: fiyatların fonksiyonu olarak n adet malın **arzı** (*supply*)
 - $D(p)$: fiyatların fonksiyonu olarak n adet mala olan **talep** (*demand*)
 - denklem: $f(p) = S(p) - D(p)$
- ▶ kimyasal/biyolojik denge: $C(c) = G(c)$ 'yi sağlayan **derişim** (*concentration*) vektörü c 'yi bul ($c \in \mathbb{R}^n$)
 - $C(c)$: derişimlerin fonksiyonu olarak n adet maddenin/türün **tüketimi** (*consumption*)
 - $G(c)$: derişimlerin fonksiyonu olarak n adet maddenin/türün **üretimi** (*generation*)
 - denklem: $f(c) = C(c) - G(c)$

Örnek: Erim ölçümleriyle konum kestirme

- ▶ $x \in \mathbb{R}^3$: 3 boyutlu konum; x 'i kestirmek istiyoruz
- ▶ **erim ölçümleri** (*range measurements*) bilinen konumlara olan gürültülü uzaklıkları verir:

$$\rho_i = \|x - a_i\| + v_i, \quad i = 1, \dots, m$$

- ▶ a_i : bilinen konumlar; v_i : gürültüler
- ▶ en küçük kareler konum kestirme:

$$\sum_{i=1}^m (\|x - a_i\| - \rho_i)^2$$

ifadesini minimize eden \hat{x} 'i bulmak

- ▶ **küresel konum belirleme sistemi** (*global positioning system* (GPS)) bu şekilde çalışır

Bölüm 2

Levenberg-Marquardt algoritması

Levenberg-Marquardt algoritması

Levenberg-Marquardt algoritması için temel fikir:

- $f(x)$ için herhangi bir z noktasında

$$\hat{f}(x; z) = f(z) + Df(z)(x - z)$$

şeklinde bir afin yaklaşıklık oluşturabiliriz

- x, z 'ye yakın ise $\hat{f}(x; z) \approx f(x)$ olur
- $\|\hat{f}(x; z)\|^2$ 'yi doğrusal en küçük kareler ile minimize edebiliriz
- z 'yi şu anki **döngü adımı** (*iterate*) olarak kullanarak **döngülü** (*iterative*) şekilde çözümü hesaplamaya çalışırız
- Levenberg-Marquardt algoritmasına “**sönümlü** (*damped*) en küçük kareler yöntemi” de denir

Levenberg-Marquardt algoritması

- ▶ döngü adımlarını $x^{(1)}, x^{(2)}, \dots$ ile gösterelim
- ▶ döngü k 'de, f 'in $x^{(k)}$ 'deki afin yaklaşıklığını oluşturalım:

$$\hat{f}(x; x^{(k)}) = f(x^{(k)}) + Df(x^{(k)})(x - x^{(k)})$$



$$\|\hat{f}(x; x^{(k)})\|^2 + \lambda^{(k)} \|x - x^{(k)}\|^2$$

ifadesini minimize eden noktayı, $x^{(k+1)}$ döngü adımı olarak seçelim (burada $\lambda^{(k)} > 0$ **sönüm çarpanı** (*damping factor*))

- ▶ $\|\hat{f}(x; x^{(k)})\|^2$ küçük olsun isteriz ancak $x^{(k)}$ 'ten çok fazla uzaklaşmak istemeyiz (çünkü $x^{(k)}$ 'ten çok fazla uzaklaşınca $\hat{f}(x; x^{(k)}) \approx f(x)$ geçerliliğini yitirir)

Levenberg-Marquardt döngüsü

► $x^{(k+1)}$,

$$\underset{x}{\text{minimize}} \quad \|f(x^{(k)}) + Df(x^{(k)})(x - x^{(k)})\|^2 + \lambda^{(k)}\|x - x^{(k)}\|^2$$

şeklindeki en küçük kareler probleminin çözümüdür

► çözüm aşağıdaki şekilde hesaplanabilir

$$x^{(k+1)} = x^{(k)} - \left(Df(x^{(k)})^T Df(x^{(k)}) + \lambda^{(k)} I \right)^{-1} Df(x^{(k)})^T f(x^{(k)})$$

► çözüm ifadesindeki matris tersi daima mevcuttur (çünkü $\lambda^{(k)} > 0$)

► ancak $Df(x^{(k)})^T f(x^{(k)}) = 0$ olduğunda (yani, optimalite koşulu sağlandığında) $x^{(k+1)} = x^{(k)}$ olur

Levenberg-Marquardt algoritması

$\lambda^{(k)}$ 'yi ayarlamak - fikir:

- ▶ $\lambda^{(k)}$ çok büyük ise $x^{(k+1)}$ $x^{(k)}$ 'e çok yakın olur ve algoritmanın ilerlemesi yavaş olur
- ▶ $\lambda^{(k)}$ çok küçük ise $x^{(k+1)}$ $x^{(k)}$ 'e çok uzak olur ve afin yaklaşıklık ($\hat{f}(x; x^{(k)}) \approx f(x)$) kötü olur (başka bir deyişle: $\hat{f}(x; x^{(k)})$, $f(x)$ 'i yeteri kadar iyi temsil edemez)

$\lambda^{(k)}$ 'yi ayarlamak - güncelleme mekanizması:

- ▶ $\|f(x^{(k+1)})\|^2 < \|f(x^{(k)})\|^2$ ise, hesaplanan yeni $x^{(k+1)}$ değerini kabul et ve λ 'yı azalt:



$$\lambda^{(k+1)} = 0.8\lambda^{(k)}$$

- ▶ aksi halde, λ 'yı arttır ve $x^{(k)}$ 'i güncelleme:

$$\lambda^{(k+1)} = 2\lambda^{(k)} \quad x^{(k+1)} = x^{(k)}$$

Levenberg-Marquardt algoritması


örnek: erim ölçümleriyle konum kestirme



- ▶ soldaki grafik: $\|f(x)\|^2$ 'in **seviye eğrileri** (*level curves* veya *contour lines*)
- ▶ sağdaki grafik: $\|f(x)\|$
- ▶ mavi daireler: 5 konum (bu konumlara olan ölçümler veri)
- ▶ kırmızı kare: konum kestirimi \hat{x}

Levenberg-Marquardt algoritması



örnek: erim ölçümleriyle konum kestirme



algoritmanın 3 farklı başlangıç noktasından çalıştırılmasıyla elde edilen döngü adımı yörüngeleri

Levenberg-Marquardt algoritması

örnek: erim ölçümleriyle konum kestirme



algoritmanın 3 farklı başlangıç noktasından çalıştırılmasıyla elde edilen “döngü adımı için amaç fonksiyonu değeri” (yani, $\|f(x^{(k)})\|^2$) ve sönüm çarpanı $\lambda^{(k)}$ grafikleri

Bölüm 3

Doğrusal olmayan model uydurma

Doğrusal olmayan model uydurma

doğrusal olmayan model uydurma problemi:

$$\underset{\theta}{\text{minimize}} \quad \sum_{i=1}^N \left(\hat{f}(x^{(i)}; \theta) - y^{(i)} \right)^2$$

- ▶ $x^{(i)}, \dots, x^{(N)}$: öznitelik vektörleri
- ▶ $y^{(i)}, \dots, y^{(N)}$: karşılık gelen sonuçlar
- ▶ model $\hat{f}(x; \theta)$, parametreler $\theta_1, \dots, \theta_p$ ile parametrelendirilmiştir
- ▶ bu model formu,


$$\hat{f}(x; \theta) = \theta_1 f_1(x) + \dots + \theta_p f_p(x)$$

formundaki “parametrelere göre doğrusal” modelin genelleştirilmiş halidir

- ▶ burada $\hat{f}(x; \theta)$ 'in, θ 'nın doğrusal olmayan bir fonksiyonu olmasına izin veriyoruz
- ▶ minimizasyon, model parametreleri θ üzerinden olur

Doğrusal olmayan model uydurma - Örnek

model: $\hat{x}(x; \theta) = \theta_1 \exp(\theta_2 x) \cos(\theta_3 x + \theta_4)$



dört parametrelili $(\theta_1, \theta_2, \theta_3, \theta_4)$ bir doğrusal olmayan en küçük kareler problemi:

$$\underset{\theta}{\text{minimize}} \quad \sum_{i=1}^N \left(\theta_1 \exp(\theta_2 x^{(i)}) \cos(\theta_3 x^{(i)} + \theta_4) - y^{(i)} \right)^2$$

Bölüm 4

Doğrusal olmayan en küçük kareler
sınıflandırma

NLS sınıflandırma

doğrusal en küçük kareler sınıflandırıcı:

- ▶ sınıflandırıcı: $\hat{f}(x) = \text{sign}(\tilde{f}(x))$
- ▶ $\tilde{f}(x) = \theta_1 f_1(x) + \dots + \theta_p f_p(x)$
- ▶ $\sum_{i=1}^N (\tilde{f}(x_i) - y_i)^2$ (buna opsiyonel olarak düzenleme terimi eklenebilir) minimize edilerek θ seçilir

doğrusal olmayan en küçük kareler (NLS) sınıflandırıcı:

- ▶ asıl problem


$$\sum_{i=1}^N (\text{sign}(\tilde{f}(x_i)) - y_i)^2$$

minimize edilerek θ 'yı seçme şeklinde formüle edilir

- ▶ buradaki sign fonksiyonu, pürüzsüz yaklaşıklığı ϕ (örneğin, sigmoit fonksiyonu) ile değiştirilir
- ▶ Levenberg-Marquardt algoritması kullanılarak $\sum_{i=1}^N (\phi(\tilde{f}(x_i)) - y_i)^2$ minimize edilir

Sigmoid fonksiyonu

$$\phi(u) = \frac{e^u - e^{-u}}{e^u + e^{-u}}$$

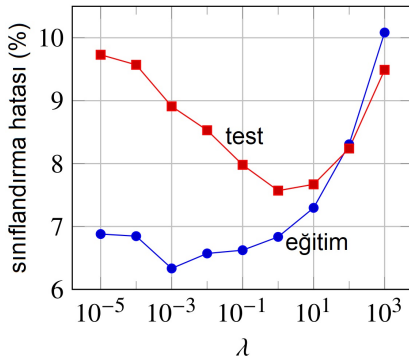


NLS sınıflandırma - Örnek: El yazısı rakam

- ▶ MNIST veri kümesi; öznitelik vektörü $x \in \mathbb{R}^{493}$ piksel yoğunlukları (her x bir el yazısı rakam görüntüsü)
- ▶ 10- Taraflı çok-sınıflı NLS sınıflandırıcı: %7.5 test hatası
- ▶ Boole sınıflandırıcılar

$$\underset{\beta, \nu}{\text{minimize}} \quad \sum_{i=1}^N (\phi((x^{(i)})^T \beta + \nu) - y^{(i)})^2 + \lambda \|\beta\|^2$$

şeklindeki NLS problemleri çözülerek hesaplanır



NLS sınıflandırma - Örnek: El yazısı rakam

öznitelik mühendisliği:

- ▶ formülasyona 5000 adet rastgele öznitelik ekleyelim
- ▶ bu durumda test veri kümesi için %2'lik hata oluşur
- ▶ bu seviyedeki hata insan başarımına denktir
- ▶ daha fazla/daha iyi öznitelik mühendisliği ile insan başarımından çok daha yüksek başarımlar elde edilebilir

Bölüm 5

Kısıtlı doğrusal olmayan en küçük kareler

Alt Bölüm 1

Problem formülasyonu

Kısıtlı doğrusal olmayan en küçük kareler

- doğrusal olmayan en küçük kareler problemine eşitlik kısıtları ekleyelim:

$$\underset{x}{\text{minimize}} \quad f_1(x)^2 + \cdots + f_m(x)^2$$

$$\text{bağlı} \quad g_1(x) = 0, \dots, g_p(x) = 0$$

- $f_i(x)$: i . (skaler) kalıntı; $g_i(x) = 0$: i . (skaler) eşitlik kısıtı
- vektör notasyonu ile, yani

$$f(x) = \begin{bmatrix} f_1(x) \\ \vdots \\ f_m(x) \end{bmatrix} \quad g(x) = \begin{bmatrix} g_1(x) \\ \vdots \\ g_p(x) \end{bmatrix} = 0$$

ile, problem aşağıdaki şekilde yazılabilir:

$$\underset{x}{\text{minimize}} \quad \|f(x)\|^2$$

$$\text{bağlı} \quad g(x) = 0$$

Kısıtlı doğrusal olmayan en küçük kareler

- ▶ $g(x) = 0$ koşulunu (yani, kısıtları) sağlayan x 'e **olanaklı** (*feasible*) denir
- ▶ bir \hat{x} noktası olanaklı ise ve bütün olanaklı x 'ler için $\|f(x)\|^2 \geq \|f(\hat{x})\|^2$ koşulu sağlanıyorsa, \hat{x} noktası bir **çözümdür** (*solution*)
- ▶ kısıtlı doğrusal olmayan en küçük kareler (*constrained nonlinear least squares* (CNLS)) problemini çözmek genel olarak zordur, ancak yararlı **buluşsal yöntemler** (*heuristics*) mevcuttur

Lagrange çarpanları

- CNLS probleminin **Lagrange fonksiyonu** (*Lagrangian*)

$$\begin{aligned}L(x, z) &= \|f(x)\|^2 + z_1 g_1(x) + \dots + z_m g_m(x) \\ &= \|f(x)\|^2 + g(x)^T z\end{aligned}$$

şeklinde tanımlı fonksiyondur

- $z = [z_1 \ \dots \ z_p]^T$: Lagrange **çarpanları** (*multiplier*) vektörü ($z \in \mathbb{R}^p$)
- Lagrange çarpanları yöntemi: \hat{x} bir çözüm ise

$$\frac{\partial L}{\partial x_i}(\hat{x}, \hat{z}) = 0, \quad i = 1, \dots, n \qquad \frac{\partial L}{\partial z_i}(\hat{x}, \hat{z}) = 0, \quad i = 1, \dots, p$$

koşullarını sağlayan bir \hat{z} mevcuttur (gradyanlardan $(\nabla g_1(\hat{x}), \dots, \nabla g_p(\hat{x}))$ oluşan vektör kümesinin doğrusal bağımsız olması koşuluyla)

- \hat{z} bir optimal Lagrange çarpanıdır

Optimalite koşulu

- Lagrange fonksiyonunun x 'e göre gradyanı:

$$\nabla_x L(\hat{x}, \hat{z}) = 2Df(\hat{x})^T f(\hat{x}) + Dg(\hat{x})^T \hat{z}$$

- Lagrange fonksiyonunun z 'ye göre gradyanı:

$$\nabla_z L(\hat{x}, \hat{z}) = g(\hat{x})$$

- optimalite koşulu: \hat{x} optimal ise

$$2Df(\hat{x})^T f(\hat{x}) + Dg(\hat{x})^T \hat{z} = 0, \quad g(\hat{x}) = 0$$

koşullarını sağlayan bir \hat{z} mevcuttur ($Dg(\hat{x})$ 'in satırlarından oluşan vektör kümesinin doğrusal bağımsız olması koşuluyla)

- bu koşul optimalite için **gerekli**dir (*necessary*) ancak **yeterli** (*sufficient*) değildir

Kısıtlı (doğrusal) en küçük kareler

- kısıtlı en küçük kareler problemini hatırlayalım:

$$\begin{aligned} \underset{x}{\text{minimize}} \quad & \|Ax - b\|^2 \\ \text{bağlı} \quad & Cx = d \end{aligned}$$

- bu, doğrusal olmayan problemin $f(x) = Ax - b$, $g(x) = Cx - d$ ile oluşan bir özel halidir
- probleme genel optimalite koşulunu uygulayalım:

$$\begin{aligned} 2Df(\hat{x})^T f(\hat{x}) + Dg(\hat{x})^T \hat{z} &= 2A^T(A\hat{x} - b) + C^T \hat{z} = 0 \\ g(\hat{x}) &= C\hat{x} - d = 0 \end{aligned}$$

- bunlar KKT denklemleridir

$$\begin{bmatrix} 2A^T A & C^T \\ C & 0 \end{bmatrix} \begin{bmatrix} \hat{x} \\ \hat{z} \end{bmatrix} = \begin{bmatrix} 2A^T b \\ d \end{bmatrix}$$

Alt Bölüm 2

Ceza yöntemi

Ceza yöntemi

- (kısıtsız) doğrusal olmayan en küçük kareler problemleri dizisini çözelim

$$\underset{x}{\text{minimize}} \quad \|f(x)\|^2 + \mu \|g(x)\|^2 = \left\| \begin{bmatrix} f(x) \\ \sqrt{\mu} g(x) \end{bmatrix} \right\|^2$$

- μ : **ceza** (*penalty*) parametresi ($\mu > 0$)
- $g(x) = 0$ koşulunun sağlanmasında ısrar etmek yerine, burada sıfırdan olan sapmalar için bir ceza terimi oluşturuyoruz
- artan $\mu^{(1)}, \mu^{(2)}, \dots$ dizisi için

$$\|f(x)\|^2 + \mu^{(k)} \|g(x)\|^2$$

minimize ederek $x^{(k+1)}$ hesaplanır

- burada $x^{(k+1)}, x^{(k)}$ noktasından başlatılan Levenberg-Marquardt algoritmasıyla hesaplanır

Ceza yönteminin sonlanması

- ▶ CNLS için optimalite koşulunu hatırlayalım:

$$2Df(\hat{x})^T f(\hat{x}) + Dg(\hat{x})^T \hat{z} = 0, \quad g(\hat{x}) = 0$$

- ▶ $x^{(k)}$, doğrusal LS problemi için normal denklemleri sağlar:

$$2Df(x^{(k)})^T f(x^{(k)}) + 2\mu^{(k-1)} Dg(x^{(k)})^T g(x^{(k)}) = 0$$

- ▶ bunu, $z^{(k)} = 2\mu^{(k-1)} g(x^{(k)})$ tanımıyla

$$2Df(x^{(k)})^T f(x^{(k)}) + Dg(x^{(k)})^T z^{(k)} = 0$$


şeklinde yazabiliriz

- ▶ buradan $x^{(k)}, z^{(k)}$ 'nin optimalite koşulundaki birinci denklemi sağladığını görüyoruz
- ▶ olanaklılık koşulu $g(x^{(k)}) = 0$ yeteri kadar büyük $\mu^{(k-1)}$ için ve ancak yaklaşık olarak sağlanır
- ▶ $\|g(x^{(k)})\|$ yeteri kadar küçük olduğunda ceza yöntemi sonlanır (**sonlanma**: *termination*)

Ceza yöntemi - Örnek

$$f(x_1, x_2) = \begin{bmatrix} x_1 + \exp(-x_2) \\ x_1^2 + 2x_1 + 1 \end{bmatrix}$$

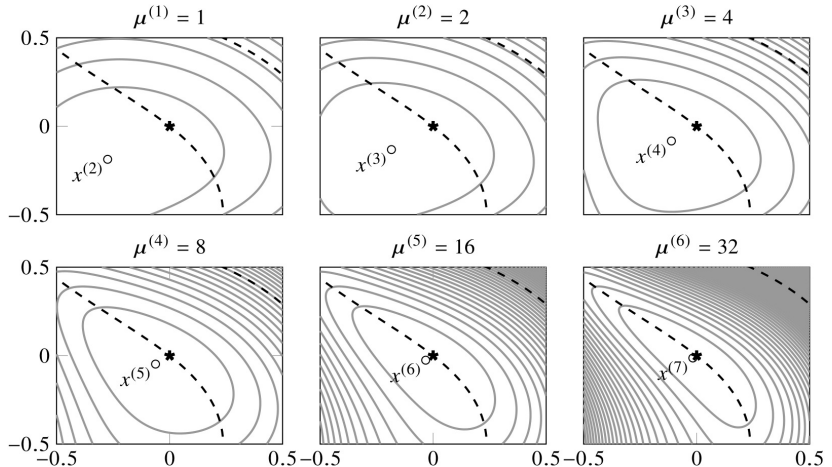
$$g(x_1, x_2) = x_1 + x_1^3 + x_2 + x_2^2$$



- ▶ düz çizgi: $\|f(x)\|^2$ için seviye eğrileri
- ▶ kesikli çizgi: $g(x)$ için seviye eğrileri
- ▶ \hat{x} : problemin çözümü

Ceza yöntemi - Örnek

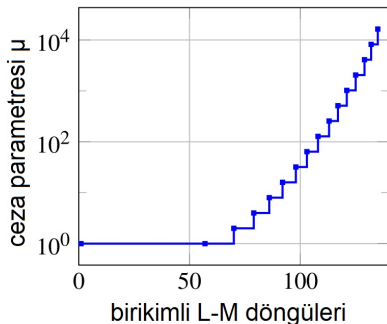

ilk 6 yineleme adımı



- düz çizgi: $\|f(x)\|^2 + \mu^{(k)}\|g(x)\|^2$ için seviye eğrileri
- kesikli çizgi: $g(x)$ için seviye eğrileri

Ceza yöntemi - Örnek

yakınsama (*convergence*)



- ▶ soldaki grafik optimalite koşulundaki kalıntıları gösteriyor
- ▶ mavi eğri: $\|g(x^{(k)})\|$ (olanaklılık için bu küçük olsun (idealde 0 olsun) isteriz)
- ▶ kırmızı eğri: $2Df(x^{(k)})^T f(x^{(k)}) + Dg(x^{(k)})^T z^{(k)}$ (optimalite için bu küçük olsun (idealde 0 olsun) isteriz)

Alt Bölüm 3

Artırılmış Lagrange fonksiyonu yöntemi

Ceza yönteminin dezavantajı

- ▶ $\mu^{(k)}$ hızlı bir şekilde artar ve $g(x)$ 'in 0'a yakın bir değer almasını sağlamak için $\mu^{(k)}$ büyük bir değer almak zorundadır
- ▶ büyük $\mu^{(k)}$ için doğrusal olmayan en küçük kareler **altproblemini (subproblem)** çözmek zorlaşır
- ▶ büyük $\mu^{(k)}$ için, Levenberg-Marquardt yöntemi çok sayıda döngü yapmak zorunda kalabilir, veya başarısız olabilir (yani, altprobleme çözüm bulamadan sonlanabilir)

Artırılmış Lagrange fonksiyonu

- kısıtlı doğrusal olmayan en küçük kareler problemi için **artırılmış** (*augmented*) Lagrange fonksiyonu:

$$\begin{aligned}L_{\mu}(x, z) &= L(x, z) + \mu \|g(x)\|^2 \\ &= \|f(x)\|^2 + g(x)^T z + \mu \|g(x)\|^2\end{aligned}$$

- $L_{\mu}(x, z)$, (standart) Lagrange fonksiyonu $L(x, z)$ 'nin bir karesel ceza terimi ($\|g(x)\|^2$) ile artırılmış halidir
- μ : **ceza** (*penalty*) parametresi ($\mu > 0$)
- artırılmış Lagrange fonksiyonu $L_{\mu}(x, z)$,

$$\begin{array}{ll}\underset{x}{\text{minimize}} & \|f(x)\|^2 + \mu \|g(x)\|^2 \\ \text{bağlı} & g(x) = 0\end{array}$$

şeklindeki (asıl probleme denk) problemin Lagrange fonksiyonudur

Artırılmış Lagrange fonksiyonu

artırılmış Lagrange fonksiyonunun minimize edilmesi:

- artırılmış Lagrange fonksiyonu $L_\mu(x, z)$ için denk ifadeler

$$\begin{aligned}L_\mu(x, z) &= \|f(x)\|^2 + g(x)^T z + \mu \|g(x)\|^2 \\&= \|f(x)\|^2 + \mu \|g(x) + \frac{1}{2\mu} z\|^2 - \frac{1}{2\mu} \|z\|^2 \\&= \left\| \begin{bmatrix} f(x) \\ \sqrt{\mu} g(x) + \frac{z}{2\sqrt{\mu}} \end{bmatrix} \right\|^2 - \frac{1}{2\mu} \|z\|^2\end{aligned}$$

- $L_\mu(x, z)$, Levenberg-Marquardt yöntemiyle x 'e göre (sabit μ ve z için) minimize edilebilir:

$$\underset{x}{\text{minimize}} \quad \left\| \begin{bmatrix} f(x) \\ \sqrt{\mu} g(x) + \frac{z}{2\sqrt{\mu}} \end{bmatrix} \right\|^2$$

Lagrange çarpanlarının güncellenmesi

- $L_\mu(x, z)$ 'yi minimize eden \tilde{x} noktası

$$2Df(\tilde{x})^T f(\tilde{x}) + Dg(\tilde{x})^T (2\mu g(\tilde{x}) + z) = 0$$

denklemini sağlar

- $\tilde{z} = z + 2\mu g(\tilde{x})$ tanımıyla, bu denklemi aşağıdaki şekilde yazabiliriz:

$$2Df(\tilde{x})^T f(\tilde{x}) + Dg(\tilde{x})^T \tilde{z} = 0$$

- bu denklem,

$$2Df(\hat{x})^T f(\hat{x}) + Dg(\hat{x})^T \hat{z} = 0, \quad g(\hat{x}) = 0$$

şeklinde yazdığımız optimalite koşulundaki birinci denklemdir

- bu denklem, $g(\tilde{x}) = 0$ ise \tilde{x} 'in optimal olduğunu gösterir
- ayrıca, $g(\tilde{x})$ küçük değilse, \tilde{z} 'nin z için iyi bir güncelleme olduğuna işaret eder

Artırılmış Lagrange fonksiyonu algoritması

1. başlangıç noktası $x^{(k)}$ için Levenberg-Marquardt algoritmasını kullanarak

$$\|f(x)\|^2 + \mu^{(k)} \|g(x) + \frac{1}{2\mu^{(k)}} z^{(k)}\|^2$$

ifadesini minimize eden noktayı $x^{(k+1)}$ olarak seç

2. *Lagrange çarpanlarını güncelle:*

$$z^{(k+1)} = z^{(k)} + 2\mu^{(k)} g(x^{(k+1)})$$


3. *ceza parametresini güncelle:*

$$\mu^{(k+1)} = \begin{cases} \mu^{(k)} & \|g(x^{(k+1)})\| < 0.25 \|g(x^{(k)})\| \text{ ise} \\ 2\mu^{(k)} & \text{aksi halde} \end{cases}$$

- döngü $z^{(1)} = 0$, $\mu^{(1)} = 1$ ve verilen başlangıç noktası $x^{(1)}$ ile başlar
- μ , ceza yöntemine göre daha yavaş bir şekilde ve sadece gerektiğinde arttırılır

Artırılmış Lagrange fonks. yöntemi - Örnek

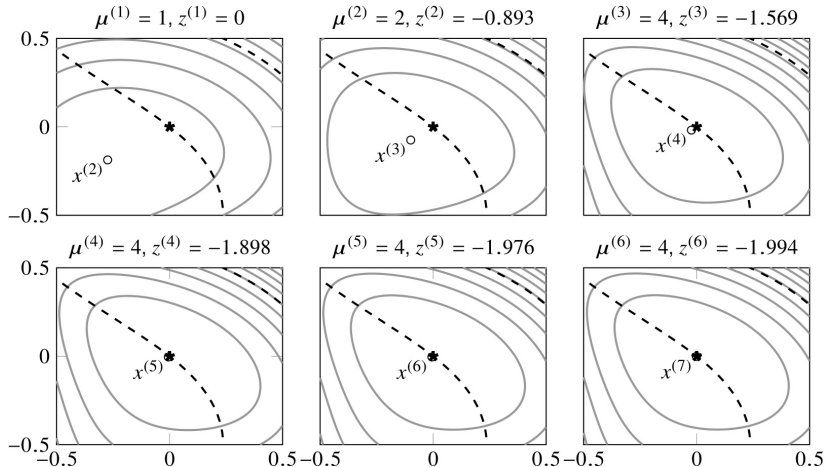
$$f(x_1, x_2) = \begin{bmatrix} x_1 + \exp(-x_2) \\ x_1^2 + 2x_1 + 1 \end{bmatrix} \quad g(x_1, x_2) = x_1 + x_1^3 + x_2 + x_2^2$$



- ▶ düz çizgi:
 $\|f(x)\|^2$ için
seviye eğrileri
- ▶ kesikli çizgi:
 $g(x)$ için
seviye eğrileri
- ▶ \hat{x} : problemin
çözümü

Artırılmış Lagrange fonks. yöntemi - Örnek


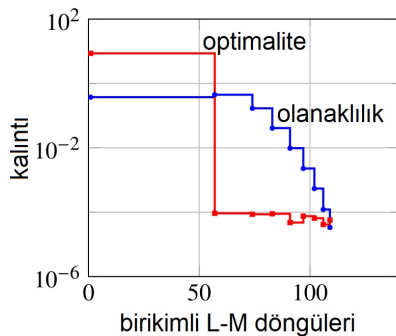
ilk 6 yineleme adımı



- düz çizgi: $L_{\mu^{(k)}}(x, z^{(k)})$ için seviye eğrileri
- kesikli çizgi: $g(x)$ için seviye eğrileri

Artırılmış Lagrange fonks. yöntemi - Örnek

yakınsama (*convergence*)




- ▶ soldaki grafik optimalite koşulundaki kalıntıları gösteriyor
- ▶ mavi eğri: $\|g(x^{(k)})\|$ (olanaklılık için bu küçük olsun (idealde 0 olsun) isteriz)
- ▶ kırmızı eğri: $2Df(x^{(k)})^T f(x^{(k)}) + Dg(x^{(k)})^T z^{(k)}$ (optimalite için bu küçük olsun (idealde 0 olsun) isteriz)

Alt Bölüm 4

Örnek: Doğrusal olmayan kontrol

Arabanın basit modeli



$$\begin{aligned}\frac{dp_1}{dt} &= s(t) \cos(\theta(t)) \\ \frac{dp_2}{dt} &= s(t) \sin(\theta(t)) \\ \frac{d\theta}{dt} &= \frac{s(t)}{L} \tan(\phi(t))\end{aligned}$$

- ▶ $s(t) \in \mathbb{R}$: **sürat** (*speed*)
- ▶ $\phi(t) \in \mathbb{R}$: **direksiyon açısı** (*steering angle*)
- ▶ $p(t) \in \mathbb{R}^2$: **konum** (*position*)
- ▶ $\theta(t) \in \mathbb{R}$: **yönelim** (*orientation*)

Zamanda ayırıklaştırılmış model

- ▶ zamanda **ayırıklaştırılmış** (*discretized*) model (küçük bir **zaman aralığı** (*time interval*) h değeri için):

$$p_1(t+h) \approx p_1(t) + hs(t) \cos(\theta(t))$$

$$p_2(t+h) \approx p_2(t) + hs(t) \sin(\theta(t))$$

$$\theta(t+h) \approx \theta(t) + h \frac{s(t)}{L} \tan(\phi(t))$$

- ▶ durum (x_k) ve giriş (u_k) vektörlerini tanımlayalım:

$$x_k = \begin{bmatrix} p_1(kh) \\ p_2(kh) \\ \theta(kh) \end{bmatrix} \quad u_k = \begin{bmatrix} s(kh) \\ \phi(kh) \end{bmatrix}$$

- ▶ zamanda ayırıklaştırılmış modeli

$$f(x_k, u_k) = \begin{bmatrix} (x_k)_1 + h(u_k)_1 \cos((x_k)_3) \\ (x_k)_2 + h(u_k)_1 \sin((x_k)_3) \\ (x_k)_3 + h \frac{(u_k)_2}{L} \tan((u_k)_2) \end{bmatrix}$$

ile $x_{k+1} = f(x_k, u_k)$ formunda yazabiliriz

Kontrol problemi

- ▶ arabayı verilen başlangıç konumu ve yöneliminden istenen son konuma ve yönetime doğru hareket ettirmek istiyoruz
- ▶ bu işlemi küçük ve yavaş değişen bir giriş dizisi kullanarak yapmak istiyoruz
- ▶ bu, bir kısıtlı doğrusal olmayan en küçük kareler problemidir:

$$\text{minimize} \quad \sum_{k=1}^N \|u_k\|^2 + \gamma \sum_{k=1}^{N-1} \|u_{k+1} - u_k\|^2$$

$$\text{bağlı} \quad x_1 = x_{\text{başlangıç}} = 0$$

$$k = 1, 2, \dots, N - 1 \text{ için :}$$


$$x_{k+1} = f(x_k, u_k)$$

$$x_{\text{son}} = f(x_N, u_N)$$


- ▶ problemin değişkenleri: $x_2, \dots, x_N, u_1, \dots, u_N$

Dört çözüm yörüngesi


$$x_{\text{final}} = (0, 1, 0)$$




$$x_{\text{final}} = (0, 1, \pi/2)$$



$$x_{\text{final}} = (0, 0.5, 0)$$



$$x_{\text{final}} = (0.5, 0.5, -\pi/2)$$



Dört çözüm yörüngesi için giriş dizileri

