

Tekil Değer Ayırıştırması

T.C. Trakya Üniversitesi
Mühendislik Fakültesi
Elektrik - Elektronik Mühendisliği Bölümü
Kontrol Anabilim Dalı

Dr. Öğr. Üyesi Işık İlber Sirmatel
sirmatel.github.io

Kaynak (source)

*Lecture slides for Introduction to
Linear Dynamical Systems*

Stephen Boyd

Konu listesi

1. Tekil değer ayrıştırması
2. Tekil değer ayrıştırmasının yorumları
3. Tekil değer ayrıştırması uygulamaları

Bölüm 1

Tekil değer ayrıştırması

Tekil değer ayrıştırması (SVD)

bir $A \in \mathbb{R}^{m \times n}$ matrisinin **tekil değer ayrıştırması** (*singular value decomposition*) (SVD)

$$A = U\Sigma V^T$$

şeklinde ifade edilir

- ▶ bir matrisin tekil değer ayrıştırması daima mevcuttur
- ▶ $\text{rank}(A) = r$
- ▶ $U \in \mathbb{R}^{m \times r}$, $U^T U = I$
- ▶ $V \in \mathbb{R}^{n \times r}$, $V^T V = I$
- ▶ $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$ ($\sigma_1 \geq \dots \geq \sigma_r > 0$)

Tekil değer ayrıştırması (SVD)

U ve V 'yi

$$U = \begin{bmatrix} u_1 & \dots & u_r \end{bmatrix} \quad V = \begin{bmatrix} v_1 & \dots & v_r \end{bmatrix}$$

şeklinde (yani, sütunlarını belirterek) yazarsak

$$A = U\Sigma V^T = \sum_{i=1}^r \sigma_i u_i v_i^T$$

yazabiliriz

- ▶ σ_i , A 'nın (sıfıra eşit olmayan) **tekil değer**leri (*singular value*)
- ▶ u_i , A 'nın **sol tekil** (*left singular*) vektörleri
- ▶ v_i , A 'nın **sağ tekil** (*right singular*) vektörleri

Tekil değer ayrıştırması (SVD)

$$A^T A = (U \Sigma V^T)^T (U \Sigma V^T) = V \Sigma^2 V^T$$

yazabiliriz

dolayısıyla:

- ▶ v_i , $A^T A$ 'nın (sıfıra eşit olmayan özdeğerlerine karşılık gelen) özvektörleridir
- ▶ $\sigma_i = \sqrt{\lambda_i(A^T A)}$ (ve, $i > r$ için $\lambda_i(A^T A) = 0$)
- ▶ $\|A\| = \sigma_1$ (yazıyla: bir matrisin (spektral) normu, o matrisin maksimum tekil değerine eşittir)

Tekil değer ayrıştırması (SVD)

benzer şekilde,

$$AA^T = (U\Sigma V^T)(U\Sigma V^T)^T = U\Sigma^2 U^T$$

yazabiliriz

dolayısıyla:

- ▶ u_i , AA^T 'nin (sıfıra eşit olmayan özdeğerlerine karşılık gelen) özvektörleridir
- ▶ $\sigma_i = \sqrt{\lambda_i(AA^T)}$ (ve, $i > r$ için $\lambda_i(AA^T) = 0$)
- ▶ u_1, \dots, u_r , $\mathcal{R}(A)$ (A 'nın sütun uzayı) için bir birim dikgen taban oluşturur
- ▶ v_1, \dots, v_r , $\mathcal{R}(A^T)$ (A 'nın satır uzayı) için bir birim dikgen taban oluşturur

Ek bilgi: Tam tekil değer ayrıştırması

$A \in \mathbb{R}^{m \times n}$ ($\text{rank}(A) = r$) için

$$A = U_1 \Sigma_1 V_1^T = \begin{bmatrix} u_1 & \cdots & u_r \end{bmatrix} \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix} \begin{bmatrix} v_1^T \\ \vdots \\ v_r^T \end{bmatrix}$$

şeklindeki SVD'ye ekonomik (veya, **ince** (*thin*)) SVD denir

- ▶ $U = \begin{bmatrix} U_1 & U_2 \end{bmatrix} \in \mathbb{R}^{m \times m}$ ve $V = \begin{bmatrix} V_1 & V_2 \end{bmatrix} \in \mathbb{R}^{n \times n}$ olacak şekilde dikgen $U_2 \in \mathbb{R}^{m \times (m-r)}$ ve $V_2 \in \mathbb{R}^{n \times (n-r)}$ matrislerini bulalım
- ▶ Σ_1 'e sıfır satır ve sütunlar ekleyerek $\Sigma \in \mathbb{R}^{m \times n}$ 'yi oluşturalım:

$$\Sigma = \left[\begin{array}{c|c} \Sigma_1 & 0_{r \times (n-r)} \\ \hline 0_{(m-r) \times r} & 0_{(m-r) \times (n-r)} \end{array} \right]$$

Ek bilgi: Tam tekil değer ayrıştırması

buradan, A 'nın **tam** (*full*) SVD'sini

$$A = U_1 \Sigma_1 V_1^T = \underbrace{\begin{bmatrix} U_1 & | & U_2 \end{bmatrix}}_U \underbrace{\left[\begin{array}{c|c} \Sigma_1 & 0_{r \times (n-r)} \\ \hline 0_{(m-r) \times r} & 0_{(m-r) \times (n-r)} \end{array} \right]}_{\Sigma} \underbrace{\begin{bmatrix} V_1^T \\ V_2^T \end{bmatrix}}_{V^T}$$


şeklinde yazabiliriz

Bölüm 2

Tekil değer ayrıştırmasının yorumları

SVD'nin eşleme adımları ile yorumu

$$A = U\Sigma V^T = \sum_{i=1}^r \sigma_i u_i v_i^T$$



doğrusal eşleme (*mapping*) $y = Ax$

- ▶ x 'in giriş yönleri (v_1, \dots, v_r) doğrultusundaki katsayılarını hesapla
- ▶ katsayıları σ_i ile **ölçekle** (*scale*)
- ▶ sonucu çıkış yönleri (u_1, \dots, u_r) doğrultusunda **yeniden oluştur** (*reconstitute*)

şeklinde adımlarına ayrıştırılabilir

SVD'nin eşleme adımları ile yorumu

not: simetrik A için SVD ile özayrışma arasındaki fark:
SVD'de giriş ve çıkış yönleri **farklı**

- ▶ v_1 en yüksek kazançlı giriş yönü
- ▶ u_1 en yüksek kazançlı çıkış yönü
- ▶ $Av_1 = \sigma_1 u_1$

SVD'nin eşleme adımları ile yorumu

SVD, giriş ve çıkış yönlerinin fonksiyonu olarak bir matrisin kazancıyla ilgili net bir fikir edinmemizi sağlar

örnek: $A \in \mathbb{R}^{4 \times 4}$, $\Sigma = \text{diag}(10, 7, 0.1, 0.05)$

- ▶ v_1 ve v_2 yönlerindeki giriş bileşenleri, A ile çarpımla kuvvetlendirilir (yaklaşık 10 kat) ve daha çok u_1 ve u_2 'nin gerdiği düzlem boyunca çıkışa yansır
- ▶ v_3 ve v_4 yönlerindeki giriş bileşenleri, A ile çarpımla zayıflatılır (yaklaşık 10 kat)
- ▶ $\frac{\|Ax\|}{\|x\|}$ 'in değeri 10 ile 0.05 arasında değişir
- ▶ A tersi alınabilir
- ▶ bazı uygulamalar için " A 'nın kertesesi esasında 2" diyebiliriz

SVD'nin eşleme adımları ile yorumu

örnek: $A \in \mathbb{R}^{2 \times 2}$, $\sigma_1 = 1$, $\sigma_2 = 0.5$

- x 'i v_1 ve v_2 doğrultusunda çöz (yani, x 'i v_1 - v_2 koordinatlarında yaz):

$$v_1^T x = 0.6, \quad v_2^T x = 0.6 \longrightarrow x = 0.5v_1 + 0.6v_2$$

- sonucu $\sigma_1 = 1$ ve $\sigma_2 = 0.5$ ile ölçekle:


$$v_1^T x \sigma_1 = 0.6 \quad v_2^T x \sigma_2 = 0.3$$

- u_1 ve u_2 doğrultusunda Ax 'i oluştur:


$$Ax = v_1^T x \sigma_1 u_1 + v_2^T x \sigma_2 u_2 = 0.5u_1 + 0.3u_2$$

SVD'nin eşleme adımları ile yorumu

örnek (devam):




SVD'nin geometrik yorumu



$$A = U\Sigma V^T$$

SVD'nin geometrik yorumu



kaynak (source): [Georg-Johann, CC BY-SA 3.0](#)

- ▶ x 'i V^T ile döndür
- ▶ sonucu Σ ile ölçekle
- ▶ sonucu U ile döndürerek Ax 'i hesapla

Bölüm 3

Tekil değer ayrıştırması uygulamaları

Genel sözde ters

$A \neq 0$ olsun. A 'nın SVD'si $A = U\Sigma V^T$ ise, A 'nın **sözde tersi** (*pseudo-inverse*)

$$A^\dagger = V\Sigma^{-1}U^T$$

şeklinde yazılabilir

A uzun matris; tam sütun kerteli (yani, $(A^T A)^{-1}$ mevcut) ise

$$A^\dagger = (A^T A)^{-1} A^T$$

ile $Ax = b$ 'nin en küçük kareler yaklaşık çözümü: $\hat{x}_{LS} = A^\dagger y$

A geniş matris; tam satır kerteli (yani, $(AA^T)^{-1}$ mevcut) ise

$$A^\dagger = A^T (AA^T)^{-1}$$

ile $Ax = b$ 'nin en küçük norm çözümü: $\hat{x}_{LN} = A^\dagger y$

SVD'nin kestirme ve evirmede kullanımı

ölçüm modeli: $y = Ax + v$. ölçülen y 'den x 'i bulmak istiyoruz

- ▶ $y \in \mathbb{R}^m$ ölçüm (*measurement*)
- ▶ $x \in \mathbb{R}^n$ kestirmek (yani, değerini tahmin etmek)
istediğimiz vektör
- ▶ $v \in \mathbb{R}^m$ ölçüm gürültüsü veya hata

(not: **kestirme** (*estimation*), **evirme** (*inversion*))

norm-sınırlı (*norm-bound*) gürültü modeli: v için $\|v\| \leq \alpha$ olduğunu varsayıyoruz ancak bunun haricinde v ile ilgili hiçbir şey bilmiyoruz (burada α gürültünün maksimum normu)

SVD'nin kestirme ve evirmede kullanımı

- $\hat{x} = By$ formundaki **kestiriciyi** (*estimator*) ele alalım
($BA = I$, yani, kestirici **yansız** (*unbiased*))

- kestirme (veya evirme) hatasına \tilde{x} diyelim:

$$\tilde{x} = \hat{x} - x = \underbrace{By}_{\hat{x}} - \underbrace{B(y - v)}_x = Bv$$

- olası kestirme hatalarının kümesi

$$\tilde{x} \in \mathcal{E}_{\text{bel}} = \{Bv \mid \|v\| \leq \alpha\}$$

ile verilen bir elipsoittir

- $x = \hat{x} - \tilde{x} \in \hat{x} - \mathcal{E}_{\text{bel}} = \hat{x} + \mathcal{E}_{\text{bel}}$, dolayısıyla: x 'in (bilmediğimiz) gerçek değeri, merkezi kestirim \hat{x} 'te olan **belirsizlik elipsoitinin** (*uncertainty ellipsoid*) elemanıdır
- iyi kestiricinin belirsizlik elipsoiti \mathcal{E}_{bel} küçük olur
($BA = I$ 'yı sağlamak koşuluyla)

SVD'nin kestirme ve evirmede kullanımı

\mathcal{E}_{bel} 'nin yarıksenleri $\alpha\sigma_i u_i$ şeklindedir (yani, B 'nin tekil değerleri ve tekil vektörleri)

hatanın normunun maksimum değeri $\alpha\|B\|$, yani

$$\|\hat{x} - x\| \leq \alpha\|B\|$$

en küçük karelerin optimalitesi: $BA = I$ koşulunu sağlayan bütün kestiricileri ele alalım; bunların belirsizlik elipsoitlerine \mathcal{E} diyelim. en küçük kareler kestirici $B_{\text{LS}} = A^\dagger$ olarak verilsin; bunun belirsizlik elipsoitine \mathcal{E}_{LS} diyelim. buradan

- ▶ $B_{\text{LS}}B_{\text{LS}}^T \leq BB^T$
- ▶ $\mathcal{E}_{\text{LS}} \subseteq \mathcal{E}$
- ▶ $\|B_{\text{LS}}\| \leq \|B\|$

yazabiliriz. sonuç olarak: en küçük kareler kestirici belirsizlik elipsoiti en küçük olan kestiricidir

SVD'nin kontrolde kullanımı

model: $y = Ax$. istenen y 'yi oluşturacak x 'i seçmek istiyoruz


- ▶ sağ tekil vektör v_i , tekil değer σ_i ile kuvvetlendirilerek, sol tekil vektör u_i ile eşlenir
- ▶ σ_i, u_i yönündeki kontrol otoritesinin bir ölçüsüdür
- ▶ $r < m \Rightarrow u_{r+1}, \dots, u_m$ yönlerinde kontrol otoritesi yok
- ▶ A geniş matris; tam satır kerteği (yani, $(AA^T)^{-1}$ mevcut) ise oluşturulabilecek y 'lerin kümesi

$$\mathcal{E} = \{y \in \mathbb{R}^m \mid y^T (AA^T)^{-1} y \leq 1\}$$

ile verilen bir elipsoittir

SVD'nin kontrolde kullanımı

örnek: katı cisme uygulanan kuvvetler. örneğin, bir taşıta (araba, uçak, roket vb.) **itki** (*thrust*) sistemleriyle çeşitli yönlerde kuvvetlerin uygulandığı bir uygulamayı ele alalım



$$A = \begin{bmatrix} a_1 & a_2 & a_3 \end{bmatrix}$$

$$= \begin{bmatrix} -1 & 0 & -1 \\ 0 & 0.5 & -0.5 \end{bmatrix}$$

$$\sigma_1 = 1.4668, \quad \sigma_2 = 0.5904$$

- ▶ $y = Ax \in \mathbb{R}^m$: cisim üzerindeki toplam kuvvet (birim: N)
- ▶ $x_i \in \mathbb{R}$: itki sistemi i 'ye sağlanan güç (birim: W)
- ▶ $\|a\|_i$: itki sistemi i 'nin **etkililiği** (*efficiency*)
- ▶ itki uygulayabileceğimiz en etkili yön büyük yarıksen (yani, u_1) yönüdür

Ana bileşenler analizi

ana bileşenler analizi (*principal component analysis* (PCA)): keşfedici veri çözümlemesi (exploratory data analysis), veri görselleştirme, ve veri ön işleme (data preprocessing) gibi uygulamalarda kullanılan bir doğrusal **boyut indirgeme** (*dimensionality reduction*) yöntemi

örnek: tıbbi veri

örneklem sayısı: 216 (kişi)

öznitelik sayısı: 4000 (gen ifadesi)

veri matrisi: $A \in \mathbb{R}^{216 \times 4000}$

etiketler: {pozitif, negatif}

121 kişi pozitif, 95 kişi negatif

figür: ilk 3 ana bileşen

uzayında veri

